

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC & KỸ THUẬT MÁY TÍNH



NHẬP MÔN TRÍ TUỆ NHÂN TẠO

Hệ thống AI Phân công Giao hàng

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân
Sinh viên thực hiện: Huỳnh Hoàng Tuấn MSSV: 2353267
Đinh Ngụy Nguyệt Hà MSSV: 2352286
Nguyễn Xuân Hoài MSSV: 2352345

Lớp: A01

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 5 2026

Mục lục

1	Giới thiệu đề tài	3
1.1	Bối cảnh và động lực	3
1.2	Mục tiêu đề tài	3
1.3	Phạm vi thực hiện	3
2	Phát biểu bài toán	4
2.1	Mô tả bài toán thực tế	4
2.2	Đầu vào của hệ thống	4
2.3	Đầu ra của hệ thống	5
2.4	Ràng buộc và tiêu chí tối ưu	5
3	Cơ sở lý thuyết	6
3.1	Thuật toán A^* trong bài toán tìm đường	6
3.2	Bài toán CSP và tối ưu phân công	7
3.3	Hệ luật IF-THEN trong suy luận tri thức	8
3.4	Mạng Bayes cho suy luận bất định	8
3.5	Decision Tree cho dự đoán ETA	9
4	Thiết kế và hiện thực hệ thống	9
4.1	Thiết kế mô-đun A: Tìm đường A^*	9
4.2	Thiết kế mô-đun B: CSP phân công giao hàng	11
4.3	Thiết kế mô-đun C: Hệ chuyên gia luật	11
4.4	Thiết kế mô-đun D: Suy luận mạng Bayes	12
4.5	Thiết kế mô-đun E: Machine Learning dự đoán ETA	12
4.6	Tích hợp toàn hệ thống	12
5	Dữ liệu và kịch bản thực nghiệm	13
5.1	Bộ dữ liệu sử dụng	13
5.2	EDA dữ liệu	14
5.3	Tiền xử lý dữ liệu	15
5.4	Các kịch bản kiểm thử	16
6	Kết quả thực nghiệm và đánh giá	16
6.1	Kết quả mô-đun học máy	17
6.2	Kết quả suy luận Bayes	17
6.3	Kết quả phân công bằng CSP	18
6.4	Đánh giá toàn hệ thống	19
7	Kết luận và hướng phát triển	20
7.1	Kết luận	20
7.2	Hướng phát triển	20

1 Giới thiệu đề tài

1.1 Bối cảnh và động lực

Trong bối cảnh thương mại điện tử và dịch vụ giao nhận phát triển mạnh, bài toán điều phối shipper ngày càng trở nên quan trọng đối với các hệ thống logistics hiện đại. Một đơn hàng giao thành công không chỉ phụ thuộc vào quãng đường di chuyển, mà còn chịu ảnh hưởng bởi nhiều yếu tố như tình trạng giao thông, loại đường, thời điểm giao, tải trọng phương tiện, mức độ ưu tiên của đơn hàng và khả năng đáp ứng của từng shipper. Nếu thực hiện phân công hoàn toàn thủ công, hệ thống rất dễ gặp phải các vấn đề như giao trễ, phân bổ tải không đều, chi phí vận hành tăng và khó phản ứng kịp với các thay đổi xảy ra theo thời gian thực.

Đề tài này được xây dựng từ nhu cầu thiết kế một hệ thống hỗ trợ ra quyết định thông minh cho bài toán điều phối giao hàng. Thay vì chỉ sử dụng một kỹ thuật đơn lẻ, nhóm định hướng phát triển một pipeline AI tích hợp nhiều thành phần: tìm kiếm đường đi, tối ưu phân công, suy luận tri thức, mô hình hóa bất định và học máy. Cách tiếp cận này giúp hệ thống không chỉ tìm được tuyến đường hợp lý mà còn ước lượng được rủi ro giao thông, dự đoán tốc độ giao hàng và đưa ra quyết định phân công phù hợp hơn với bối cảnh thực tế.

1.2 Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống **AI điều phối shipper** có khả năng tiếp nhận thông tin đơn hàng và nguồn lực giao hàng, sau đó đề xuất phương án xử lý tối ưu dựa trên nhiều kỹ thuật trí tuệ nhân tạo. Cụ thể, hệ thống hướng đến các mục tiêu sau:

- Mô hình hóa bản đồ giao thông dưới dạng đồ thị để áp dụng thuật toán A^* trong việc tìm đường đi có thời gian di chuyển tốt giữa các điểm giao nhận.
- Biểu diễn bài toán phân công đơn hàng cho shipper dưới dạng bài toán thỏa mãn ràng buộc, từ đó bảo đảm mỗi đơn được gán đúng người, không vượt quá tải trọng và thời gian làm việc cho phép.
- Xây dựng hệ luật IF-THEN nhằm suy luận thêm các yếu tố nghiệp vụ như mức độ ưu tiên, phụ phí hoặc điều kiện xử lý đặc biệt của đơn hàng.
- Mô hình hóa yếu tố bất định của giao thông bằng mạng Bayes để ước lượng xác suất xảy ra các tình huống như kẹt xe dựa trên khung giờ và loại đường.
- Huấn luyện mô hình Decision Tree để phân loại thời gian giao hàng thành hai nhóm *Fast* và *Slow*, từ đó hỗ trợ hệ thống ra quyết định tốt hơn trong bước phân công.

1.3 Phạm vi thực hiện

Trong phạm vi bài tập lớn, nhóm tập trung xây dựng một nguyên mẫu hệ thống AI cho bài toán điều phối giao hàng ở mức mô phỏng, đủ để thể hiện rõ cách tích hợp các thành phần kiến thức chính của môn học. Cụ thể, đề tài giới hạn trong các nội dung sau:

- Xây dựng mô hình đồ thị gồm các *node* và *edge* để biểu diễn mạng lưới đường đi và thời gian di chuyển giữa các vị trí.

- Thiết kế bài toán CSP theo từng cụm khu vực nhỏ (*zone*) và từng lô xử lý ngắn (*batch*) nhằm giảm độ phức tạp tính toán và phù hợp với yêu cầu phản hồi nhanh.
- Sử dụng một mô hình Bayes đơn giản với các biến như *Time_Slot*, *Road_Type* và *Traffic_Level* để suy luận tình trạng giao thông.
- Tạo dữ liệu huấn luyện tổng hợp và áp dụng Decision Tree để dự đoán nhãn giao hàng nhanh hoặc chậm dựa trên các đặc trưng của đơn hàng và điều kiện giao nhận.
- Tập trung vào giá trị minh họa học thuật và khả năng tích hợp hệ thống, chưa mở rộng sang bài toán điều phối thực tế quy mô lớn hoặc dữ liệu giao thông thời gian thực.

2 Phát biểu bài toán

2.1 Mô tả bài toán thực tế

Bài toán được đặt ra là xây dựng một hệ thống hỗ trợ điều phối shipper trong môi trường giao hàng có nhiều đơn phát sinh đồng thời. Tại mỗi thời điểm, hệ thống tiếp nhận danh sách đơn hàng cần xử lý cùng thông tin về đội ngũ shipper đang khả dụng, sau đó đưa ra quyết định phân công sao cho phù hợp với điều kiện vận hành thực tế. Điểm khó của bài toán nằm ở chỗ quyết định cuối cùng không chỉ phụ thuộc vào khoảng cách giữa các điểm giao nhận, mà còn bị chi phối bởi tình trạng giao thông, loại đường, tải trọng phương tiện, khung giờ giao hàng và mức độ ưu tiên của từng đơn.

Từ ý tưởng đề tài, nhóm mô hình hóa bài toán thành một pipeline AI gồm nhiều tầng xử lý. Trước hết, hệ thống biểu diễn bản đồ giao thông dưới dạng đồ thị gồm các *node* và *edge*, trong đó mỗi cạnh mang thông tin về khoảng cách và tốc độ tối đa cho phép. Trên đồ thị này, thuật toán A* được sử dụng để tìm đường đi có chi phí thời gian tốt. Sau đó, mạng Bayes giúp ước lượng xác suất xảy ra mức giao thông *Low*, *Medium* hoặc *High* dựa trên các yếu tố như khung giờ và loại đường. Song song với đó, mô hình Decision Tree dự đoán nhãn thời gian giao hàng *Fast* hoặc *Slow* để hỗ trợ việc đánh giá khả năng hoàn thành đơn hàng.

Sau khi có các thông tin trung gian từ các mô-đun trên, hệ thống tiếp tục sử dụng các luật IF-THEN để bổ sung tri thức nghiệp vụ như ưu tiên xử lý, cảnh báo điều kiện bất lợi hoặc điều chỉnh quyết định phân công. Cuối cùng, bài toán phân công được mô hình hóa dưới dạng CSP, trong đó các đơn hàng được gán cho shipper theo các ràng buộc chặt chẽ về tải trọng, thời gian và tính duy nhất của phép gán. Mục tiêu cuối cùng là tìm được phương án phân công khả thi và hiệu quả, giảm tổng thời gian vận hành trong khi vẫn bảo đảm chất lượng dịch vụ giao hàng.

2.2 Đầu vào của hệ thống

Đầu vào của hệ thống được chia thành nhiều nhóm dữ liệu để phục vụ cho từng mô-đun trong pipeline:

- **Dữ liệu bản đồ và đồ thị giao thông:** tập các *node* có định danh và tọa độ, cùng tập các *edge* chứa thông tin đích đến, khoảng cách và tốc độ tối đa. Đây là dữ liệu nền để thuật toán A* tính heuristic, thời gian di chuyển và tuyến đường phù hợp.

- **Dữ liệu đơn hàng:** bao gồm số lượng đơn cần giao trong một cụm, khối lượng thực tế của từng đơn, thời gian di chuyển dự kiến, loại hàng hóa và các thông tin mô tả điều kiện giao nhận.
- **Dữ liệu shipper:** gồm số lượng shipper đang khả dụng trong một vùng xử lý, tải trọng tối đa có thể chở, giới hạn thời gian làm việc của một ca cục bộ và trạng thái sẵn sàng nhận đơn.
- **Dữ liệu cho suy luận bất định:** các biến như *Time_Slot* với hai giá trị *Peak* hoặc *Normal*, *Road_Type* với hai giá trị *Main* hoặc *Alley*, và *Traffic_Level* với ba mức *Low*, *Medium* hoặc *High*.
- **Dữ liệu cho học máy:** các mẫu dữ liệu tổng hợp mô tả khoảng cách, giao thông, thời tiết, loại tòa nhà, mức ưu tiên đơn hàng và các thuộc tính liên quan khác để huấn luyện mô hình Decision Tree phân loại ETA.
- **Tập luật tri thức:** các luật IF-THEN thể hiện kinh nghiệm hoặc quy tắc nghiệp vụ, dùng để diễn giải thêm quyết định sau khi có đầu ra từ các mô-đun tìm kiếm, Bayes và học máy.

2.3 Đầu ra của hệ thống

Đầu ra mong muốn của hệ thống không chỉ là một phép gán đơn thuần, mà là một tập kết quả hỗ trợ ra quyết định trong toàn bộ quá trình điều phối:

- Tuyến đường đề xuất cho từng đơn hàng hoặc từng shipper, được tính toán từ mô hình đồ thị và thuật toán A^* .
- Xác suất hoặc mức độ giao thông dự kiến trên tuyến đường, được suy luận từ mạng Bayes.
- Nhân dự đoán thời gian giao hàng *Fast* hoặc *Slow*, do mô hình Decision Tree cung cấp.
- Các kết luận suy luận nghiệp vụ như phụ phí, cảnh báo rủi ro, hoặc mức độ ưu tiên xử lý của đơn hàng dựa trên hệ luật IF-THEN.
- Phương án phân công cuối cùng dưới dạng ma trận quyết định, trong đó mỗi đơn hàng được gán cho đúng một shipper phù hợp với các ràng buộc hệ thống.
- Các chỉ số tổng hợp như tổng chi phí thời gian vận hành, mức độ sử dụng nguồn lực shipper hoặc số lượng đơn được xử lý thành công trong mỗi đợt phân công.

2.4 Ràng buộc và tiêu chí tối ưu

Dựa trên mô hình trong file ý tưởng, bài toán phân công được giới hạn bởi các ràng buộc chính sau:

- Trong mỗi bài toán con theo *zone*, số đơn hàng và số shipper được khống chế ở quy mô vừa phải, điển hình là $N \leq 50$ và $M \leq 10$, nhằm bảo đảm thời gian xử lý hợp lý.

- Mỗi đơn hàng phải được xử lý và chỉ được gán cho đúng một shipper, tránh tình trạng bỏ sót hoặc gán trùng.
- Tổng khối lượng các đơn được gán cho một shipper không được vượt quá giới hạn tải trọng an toàn W_{max} của phương tiện.
- Tổng thời gian di chuyển dự kiến của các đơn hàng do một shipper đảm nhận không được vượt quá giới hạn thời gian làm việc cục bộ T_{max} .
- Quyết định phân công cần xét đến các yếu tố bất định như mức độ giao thông và các thông tin dự đoán ETA để hạn chế nguy cơ giao trễ.

Bên cạnh việc thỏa mãn các ràng buộc trên, hệ thống hướng tới mục tiêu tối ưu hóa tổng thể. Cụ thể, phương án phân công nên làm giảm tổng chi phí thời gian vận hành của toàn bộ đội ngũ shipper, đồng thời cải thiện khả năng giao hàng đúng hạn và phân bổ công việc cân bằng hơn giữa các shipper. Đây là tiêu chí quan trọng để đánh giá hiệu quả của hệ thống AI điều phối trong bài toán thực tế.

3 Cơ sở lý thuyết

3.1 Thuật toán A^* trong bài toán tìm đường

Thuật toán A^* là một phương pháp tìm kiếm có thông tin, thường được sử dụng để tìm đường đi tối ưu từ một trạng thái xuất phát đến trạng thái đích trên đồ thị. Ý tưởng cốt lõi của A^* là đánh giá mỗi trạng thái thông qua hàm mục tiêu $f(n) = g(n) + h(n)$, trong đó $g(n)$ là chi phí thực tế từ điểm bắt đầu đến nút n , còn $h(n)$ là giá trị heuristic ước lượng chi phí từ nút n đến đích. Nhờ kết hợp giữa chi phí đã đi và chi phí ước lượng còn lại, A^* có khả năng thu hẹp không gian tìm kiếm và tìm được lời giải hiệu quả hơn so với các phương pháp không dùng heuristic.

Trong bài toán điều phối giao hàng, nhóm biểu diễn bản đồ dưới dạng đồ thị gồm các *node* và *edge*. Mỗi *node* chứa định danh và tọa độ, còn mỗi *edge* lưu thông tin về nút đích, khoảng cách và tốc độ tối đa cho phép. Từ đó, thời gian di chuyển trên mỗi cạnh có thể được tính từ khoảng cách và tốc độ, còn heuristic có thể được xây dựng từ khoảng cách Euclid giữa nút hiện tại và nút đích, chia cho tốc độ tối đa toàn cục để ước lượng thời gian còn lại. Theo mô hình trong file ý tưởng, thuật toán sử dụng các cấu trúc như *open_set*, *g_score*, *f_score* và *came_from* để quản lý quá trình tìm kiếm và truy vết đường đi tối ưu.

Để mô tả rõ hơn cơ chế tính chi phí, báo cáo sử dụng ba công thức cốt lõi của A^* . Trước hết, khoảng cách Euclid giữa hai điểm tọa độ được dùng làm cơ sở cho heuristic:

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}.$$

Tiếp theo, thời gian di chuyển trên một cạnh được tính từ độ dài quãng đường và vận tốc cho phép:

$$t = \frac{\text{Distance}}{\text{Speed}}.$$

Từ hai thành phần đó, hàm đánh giá của A^* được xác định bởi

$$f(n) = g(n) + h(n),$$

trong đó $g(n)$ là chi phí thực tế đã tích lũy từ điểm xuất phát đến nút n , còn $h(n)$ là chi phí ước lượng từ n đến đích.

A^* phù hợp với bài toán này vì mục tiêu không chỉ là tìm một tuyến đường bất kỳ, mà là tìm tuyến đường có chi phí thời gian tốt trong điều kiện dữ liệu giao thông được mô hình hóa theo đồ thị. So với BFS hay DFS, A^* tận dụng được thông tin heuristic nên giảm số lượng nút cần duyệt. So với Dijkstra, A^* có lợi thế hơn khi đã biết rõ trạng thái đích và có thể định hướng tìm kiếm về phía mục tiêu. Vì vậy, đây là lựa chọn hợp lý cho mô-đun tìm đường trong hệ thống điều phối shipper.

3.2 Bài toán CSP và tối ưu phân công

Bài toán thỏa mãn ràng buộc (Constraint Satisfaction Problem – CSP) là một mô hình quan trọng trong AI dùng để biểu diễn các bài toán dưới dạng tập biến, miền giá trị và các ràng buộc cần phải thỏa mãn. Một nghiệm của CSP là một phép gán giá trị cho toàn bộ biến sao cho không vi phạm bất kỳ ràng buộc nào. Trong nhiều bài toán thực tế, CSP không chỉ dừng ở việc tìm nghiệm hợp lệ mà còn mở rộng sang tìm nghiệm tốt nhất theo một tiêu chí tối ưu hóa nào đó.

Đối với bài toán điều phối giao hàng, file ý tưởng mô hình hóa trạng thái phân công bằng ma trận nhị phân X kích thước $N \times M$, với N là số đơn hàng và M là số shipper khả dụng trong một cụm xử lý. Phần tử $X_{i,j} = 1$ có nghĩa là đơn hàng thứ i được gán cho shipper thứ j , còn $X_{i,j} = 0$ nghĩa là không gán. Mô hình này phải thỏa mãn nhiều ràng buộc: mỗi đơn hàng chỉ được gán đúng một shipper, tổng khối lượng các đơn của mỗi shipper không vượt quá tải trọng tối đa W_{max} , tổng thời gian di chuyển không vượt quá giới hạn T_{max} , đồng thời quy mô bài toán con được giới hạn để bảo đảm khả năng xử lý, ví dụ $N \leq 50$ và $M \leq 10$.

Trong quá trình giải, các kỹ thuật như backtracking, branch and bound hoặc các bộ giải ràng buộc như CP-SAT có thể được sử dụng để duyệt không gian nghiệm. Hàm mục tiêu hướng đến việc cực tiểu hóa tổng chi phí thời gian vận hành của toàn bộ đội ngũ giao hàng. CSP đặc biệt phù hợp với phần phân công vì bản chất của bài toán là ra quyết định dưới nhiều ràng buộc đồng thời. Khi kết hợp với đầu vào từ A^* , Bayes, Decision Tree và hệ luật, mô hình CSP giúp biến các thông tin trung gian thành một phương án phân công vừa khả thi vừa có chất lượng tốt.

Về mặt toán học, một dạng rút gọn của bài toán có thể được viết qua hàm mục tiêu và các ràng buộc cứng như sau:

$$\min \sum_{s \in \text{Shippers}} \text{WorkTime}(s).$$

Với mỗi shipper s , hai ràng buộc quan trọng nhất là giới hạn tải trọng và giới hạn thời gian ca làm việc:

$$\sum_{i \in \text{Orders}(s)} \text{Weight}_i \leq W_{\max}, \quad \sum_{i \in \text{Orders}(s)} \text{Time}_i \leq T_{\max}.$$

Các biểu thức này giúp mô hình CSP phản ánh trực tiếp giới hạn vật lý của hệ thống giao

hàng thay vì chỉ tối ưu trên lý thuyết.

3.3 Hệ luật IF–THEN trong suy luận tri thức

Hệ luật IF–THEN là một cách biểu diễn tri thức quen thuộc trong các hệ chuyên gia. Mỗi luật bao gồm hai phần: phần điều kiện *IF* mô tả tình huống hoặc tập điều kiện đầu vào, và phần kết luận *THEN* mô tả hành động, quyết định hoặc kết quả suy ra khi các điều kiện được thỏa mãn. Ưu điểm của cách biểu diễn này là trực quan, dễ giải thích và dễ gắn với tri thức miền do con người cung cấp.

Trong đề tài điều phối shipper, hệ luật IF–THEN được dùng để bổ sung tri thức nghiệp vụ mà các mô hình thống kê hoặc học máy khó diễn đạt trực tiếp. Ví dụ, luật có thể mô tả rằng nếu đơn hàng là hàng dễ vỡ và giao trong giờ cao điểm thì cần tăng mức ưu tiên hoặc gắn thêm cảnh báo xử lý. Tương tự, nếu tuyến đường có rủi ro giao thông cao và đơn hàng có mức khẩn cấp lớn thì hệ thống có thể suy ra cần phân công shipper phù hợp hơn hoặc điều chỉnh quyết định từ các mô-đun trước. Theo ý tưởng của nhóm, hệ chuyên gia có thể được xây dựng từ khoảng 14 luật để mô hình hóa các quy tắc liên quan đến loại hàng, giao thông, phụ phí, ưu tiên và các điều kiện đặc biệt khác.

Ngoài biểu diễn logic, hệ luật còn có thể được mô tả dưới dạng các công thức cộng dồn để thuận tiện cho việc hiện thực. Chẳng hạn, tổng phụ phí áp dụng cho một đơn hàng được xác định bởi

$$S_{\text{total}} = \sum (\text{Surcharge từ các rule thỏa mãn}),$$

nghĩa là mỗi luật được kích hoạt sẽ đóng góp một khoản phụ phí riêng vào kết quả cuối cùng. Tương tự, với các đơn hỏa tốc, giới hạn thời gian giao hàng có thể được cập nhật theo quy tắc

$$\text{Limit}_{\text{new}} = \text{Limit}_{\text{base}} \times 0.5.$$

Cách mô tả này giúp hệ luật vừa giữ được tính giải thích, vừa dễ kết nối với mô-đun tối ưu ở bước sau.

Về mặt suy luận, hệ luật có thể vận hành theo hướng suy diễn tiến hoặc suy diễn lùi. Trong ngữ cảnh đề tài này, suy diễn tiến thường phù hợp hơn vì hệ thống đã có sẵn dữ liệu đầu vào và đầu ra từ các mô-đun khác, từ đó kích hoạt các luật tương ứng để đưa ra kết luận. Hệ luật đóng vai trò kết nối tri thức chuyên gia với các thành phần tính toán còn lại, giúp pipeline AI không chỉ dựa vào dữ liệu mà còn phản ánh được các nguyên tắc vận hành thực tế của bài toán giao hàng.

3.4 Mạng Bayes cho suy luận bất định

Mạng Bayes được dùng để biểu diễn quan hệ phụ thuộc xác suất giữa các biến ngẫu nhiên trong điều kiện thông tin không đầy đủ. Trong bài toán điều phối giao hàng, thành phần bất định quan trọng nhất là tình trạng giao thông; vì vậy nhóm mô hình hóa ba biến chính là *Time_Slot*, *Road_Type* và *Traffic_Level*. Hai biến đầu đóng vai trò bằng chứng quan sát, còn *Traffic_Level* là biến cần suy luận.

Mô hình cần ước lượng phân phối có điều kiện $P(\text{Traffic_Level} \mid \text{Time_Slot}, \text{Road_Type})$. Kết quả suy luận được dùng để điều chỉnh thời gian di chuyển và làm đầu vào cho các mô-đun

Decision Tree, hệ luật và CSP. Cách tiếp cận này cho phép hệ thống phản ánh rủi ro giao thông dưới dạng xác suất thay vì một giả định cố định.

Trong quá trình huấn luyện từ dữ liệu đếm tần suất, xác suất có điều kiện được làm trơn bằng Laplace smoothing với $\alpha = 1$:

$$P(\text{Traffic} \mid \text{Time, Road}) = \frac{\text{count}(\text{Traffic, Time, Road}) + \alpha}{\text{count}(\text{Time, Road}) + \alpha \times |\text{Traffic States}|}.$$

Từ xác suất suy ra, hệ thống gán hệ số phạt thời gian để cập nhật ETA:

$$\text{Penalty} = \begin{cases} 1.0, & \text{nếu Traffic = Low,} \\ 1.3, & \text{nếu Traffic = Medium,} \\ 1.6, & \text{nếu Traffic = High.} \end{cases}$$

3.5 Decision Tree cho dự đoán ETA

Decision Tree là mô hình học có giám sát phù hợp với bài toán phân lớp ETA vì dễ diễn giải và xử lý tốt các biến hỗn hợp sau khi mã hóa. Trong đề tài này, mô hình dự đoán hai nhãn *Fast* và *Slow* từ các đặc trưng như khoảng cách, giao thông, thời tiết, loại tòa nhà, khung giờ và mức ưu tiên đơn hàng.

Về nguyên lý, cây quyết định chọn thuộc tính tách tốt nhất tại mỗi nút theo các tiêu chí như *Gini impurity* hoặc *Entropy*, từ đó tạo ra các luật phân lớp có khả năng giải thích được. Vì vậy, Decision Tree phù hợp để minh họa thành phần học máy và hỗ trợ trực tiếp cho bước phân công cuối của hệ thống.

Trong đó, độ đo Gini cho một nút được viết dưới dạng

$$\text{Gini} = 1 - \sum_i (p_i)^2,$$

trong đó p_i là xác suất của lớp thứ i trong nút đang xét. Khi đánh giá mô hình trên tập kiểm tra, các chỉ số chính được tính từ confusion matrix theo các công thức

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{\text{Total}}, & \text{Precision} &= \frac{TP}{TP + FP}, \\ \text{Recall} &= \frac{TP}{TP + FN}, & \text{F1} &= 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \end{aligned}$$

4 Thiết kế và hiện thực hệ thống


4.1 Thiết kế mô-đun A: Tìm đường A*

Mô-đun A được xây dựng để giải bài toán tìm đường đi giữa điểm lấy hàng và điểm giao hàng trên bản đồ giao thông. Trong bối cảnh điều phối shipper, mô-đun này có vai trò cung cấp lộ trình di chuyển và chi phí thời gian dự kiến cho từng đơn hàng, từ đó làm cơ sở cho các bước suy luận và phân công ở phía sau. So với việc chỉ ước lượng bằng khoảng cách thẳng, cách

tiếp cận dùng đồ thị giúp hệ thống phản ánh sát hơn cấu trúc đường đi thực tế và cho phép tích hợp trực tiếp với các thuật toán tìm kiếm trong AI.

Về mặt biểu diễn, bản đồ được mô hình hóa dưới dạng đồ thị có trọng số. Mỗi đỉnh biểu diễn một vị trí hoặc giao lộ với thông tin định danh và tọa độ, còn mỗi cạnh biểu diễn một đoạn đường nối giữa hai đỉnh kèm theo khoảng cách và tốc độ tối đa cho phép. Từ cách biểu diễn này, hệ thống có thể xây dựng danh sách kề để truy xuất nhanh các nút lân cận trong quá trình tìm kiếm. Chi phí trên cạnh không được đo trực tiếp bằng độ dài quãng đường mà bằng thời gian di chuyển ước tính, được tính từ khoảng cách và tốc độ cho phép, vì đây mới là đại lượng phù hợp với mục tiêu điều phối giao hàng.

Thuật toán được lựa chọn cho mô-đun A là A^* vì vừa bảo đảm hiệu quả tìm kiếm, vừa tận dụng được hàm heuristic để rút ngắn không gian duyệt. Trong quá trình thực hiện, mô-đun duy trì các cấu trúc dữ liệu cốt lõi gồm *open_set* để lưu các nút chờ xét, *g_score* để ghi nhận chi phí tốt nhất từ điểm xuất phát đến mỗi nút, *f_score* với công thức $f(n) = g(n) + h(n)$ để đánh giá mức triển vọng của từng nút, và *came_from* để truy vết lại đường đi sau khi tìm được đích. Ở mỗi bước, hệ thống chọn nút có *f_score* nhỏ nhất, duyệt các nút kề, tính chi phí thử nghiệm rồi cập nhật khi tìm được phương án tốt hơn. Khi tới đích, mô-đun sử dụng bảng truy vết để khôi phục toàn bộ lộ trình theo đúng thứ tự từ điểm đầu đến điểm cuối.



Hình 4.1: Kết quả tìm đường đi tối ưu bằng thuật toán A^* giữa các điểm giao nhận.

Điểm then chốt của A^* nằm ở hàm heuristic. Trong đề tài này, heuristic có thể được xây dựng từ khoảng cách Euclidean giữa nút hiện tại và nút đích, sau đó chuẩn hóa theo vận tốc tối đa toàn cục để ước lượng thời gian còn lại. Cách thiết kế này giữ cho heuristic đơn giản, dễ giải thích và vẫn phù hợp với bản chất bài toán. Đầu ra của mô-đun A là đường đi tốt nhất cùng thời gian di chuyển dự kiến. Kết quả này không chỉ phục vụ trực tiếp cho việc ước lượng

ETA ban đầu mà còn được dùng làm đầu vào cho mô-đun Bayes để phân tích loại đường, cũng như cung cấp cơ sở tính thời gian công việc cho mô-đun CSP ở bước phân công cuối cùng.

4.2 Thiết kế mô-đun B: CSP phân công giao hàng

Mô-đun B được thiết kế để giải bài toán phân công đơn hàng cho shipper dưới dạng bài toán thỏa mãn ràng buộc, tức CSP. Nếu mô-đun A xác định đường đi cho từng đơn và các mô-đun Bayes, Decision Tree, hệ luật cung cấp thêm thông tin về rủi ro, ETA và nghiệp vụ, thì mô-đun B là nơi tổng hợp toàn bộ những thông tin đó để đưa ra phương án phân công cuối cùng. Mục tiêu của mô-đun không chỉ là tìm một cách gán đơn hợp lệ, mà còn hướng tới phương án hợp lý về thời gian vận hành và khả năng thực thi trong thực tế.

Đầu vào của mô-đun B gồm tập đơn hàng trong một cụm giao nhận, tập shipper đang khả dụng, cùng các thuộc tính đã được tính toán ở những mô-đun trước. Trong đó, mỗi đơn hàng có thể gán với khối lượng, thời gian giao dự kiến, mức ưu tiên, ETA dự đoán hoặc các cờ nghiệp vụ; mỗi shipper có trạng thái sẵn sàng và năng lực chuyên chở tương ứng. Theo định hướng ban đầu của đề tài, để bảo đảm thời gian phản hồi và tránh làm bài toán trở nên quá lớn, hệ thống có thể chia dữ liệu theo các cụm địa lý nhỏ hoặc theo từng lô xử lý ngắn. Nhờ vậy, mô-đun CSP không phải giải một bài toán toàn cục quá phức tạp mà chỉ cần xử lý các bài toán con có kích thước kiểm soát được.

Về mặt mô hình hóa, trạng thái phân công được biểu diễn bằng ma trận nhị phân $X_{i,j}$, trong đó $X_{i,j} = 1$ nếu shipper j nhận đơn hàng i , và $X_{i,j} = 0$ trong trường hợp ngược lại. Từ biểu diễn này, hệ thống áp đặt các ràng buộc quan trọng của bài toán. Thứ nhất, mỗi đơn hàng phải được gán cho đúng một shipper để tránh bỏ sót hoặc giao trùng. Thứ hai, tổng khối lượng các đơn hàng mà một shipper nhận không được vượt quá giới hạn chuyên chở an toàn. Thứ ba, tổng thời gian dự kiến để hoàn thành công việc của một shipper phải nằm trong ngưỡng cho phép của một ca làm việc cục bộ. Ngoài ra, mô-đun cũng có thể bổ sung các ràng buộc quy mô như giới hạn số đơn và số shipper trong mỗi cụm để bảo đảm khả năng giải trong thời gian hợp lý.

Sau khi thiết lập các biến và ràng buộc, mô-đun sử dụng bộ giải CSP hoặc CP-SAT để tìm nghiệm khả thi, đồng thời tối ưu hóa một hàm mục tiêu phù hợp, chẳng hạn cực tiểu hóa tổng thời gian vận hành hoặc giảm mất cân bằng tải giữa các shipper. Điểm quan trọng là thời gian t_i đưa vào bài toán không còn là giá trị tĩnh, mà có thể đã được điều chỉnh bởi kết quả từ A*, Bayes, Decision Tree và hệ luật. Nhờ đó, nghiệm cuối cùng phản ánh đồng thời nhiều yếu tố: đường đi thực tế, rủi ro giao thông, khả năng giao nhanh hay chậm và các yêu cầu nghiệp vụ đặc thù. Đầu ra của mô-đun B là phương án phân công cuối cùng cho từng đơn hàng, đóng vai trò là kết quả vận hành trung tâm của toàn bộ hệ thống.

4.3 Thiết kế mô-đun C: Hệ chuyên gia luật

Mô-đun C được xây dựng như một hệ chuyên gia dựa trên các luật IF-THEN nhằm bổ sung tri thức nghiệp vụ cho quá trình điều phối giao hàng. Nếu các mô-đun A*, Bayes và Decision Tree cung cấp thông tin định lượng như đường đi, xác suất giao thông và nhãn ETA, thì mô-đun luật đảm nhiệm bước diễn giải ở mức nghiệp vụ để rút ra các kết luận như mức ưu tiên, phụ phí hoặc giới hạn thời gian giao hàng.

Đầu vào của mô-đun gồm tập sự kiện mô tả trạng thái đơn hàng và bối cảnh giao nhận,

chẳng hạn loại hàng, trạng thái VIP, khoảng cách, thời tiết, giờ cao điểm, mức giao thông suy luận từ Bayes và nhân ETA *Fast/Slow* từ Decision Tree. Tập tri thức được tổ chức dưới dạng các luật sản xuất IF-THEN, trong đó mỗi luật ánh xạ một tình huống sang một kết luận nghiệp vụ. Theo hướng tiếp cận của đề tài, mô-đun sử dụng suy diễn tiến: hệ thống bắt đầu từ tập sự kiện đầu vào, kích hoạt các luật thỏa mãn và sinh ra các kết luận bổ sung cho bước phân công cuối.

Đầu ra của mô-đun C là tập kết luận nghiệp vụ như *delivery_time_limit*, *priority_level* và *estimated_surcharge*. Các kết quả này đóng vai trò ràng buộc mềm và thông tin ngữ cảnh cho mô-đun CSP, giúp phương án phân công cuối cùng hợp lý hơn về mặt vận hành thực tế.

4.4 Thiết kế mô-đun D: Suy luận mạng Bayes

Mô-đun D được thiết kế nhằm suy luận tình trạng giao thông trong điều kiện thông tin đầu vào không hoàn toàn chắc chắn. Đầu vào của mô-đun gồm các biến quan sát như *Time_Slot* và *Road_Type*; từ đó hệ thống suy ra biến ẩn *Traffic_Level* với ba mức *Low*, *Medium* và *High*.

Về mặt cấu trúc, mô-đun sử dụng một mạng Bayes đơn giản trong đó *Time_Slot* và *Road_Type* là các nút cha, còn *Traffic_Level* là nút con. Trọng tâm của mô-đun là bảng xác suất có điều kiện $P(\text{Traffic_Level} \mid \text{Time_Slot}, \text{Road_Type})$. Khi nhận truy vấn mới, hệ thống trả về phân phối xác suất cho từng mức giao thông rồi chọn mức có xác suất lớn nhất làm nhãn điều hành.

Đầu ra của mô-đun D là phân phối xác suất và nhãn giao thông tương ứng để cung cấp cho Decision Tree và CSP. Nhờ đó, hệ thống bổ sung được lớp suy luận bất định vào pipeline và điều chỉnh thời gian vận hành sát hơn với thực tế.

4.5 Thiết kế mô-đun E: Machine Learning dự đoán ETA


Mô-đun E được xây dựng để dự đoán thời gian giao hàng theo hai nhãn *Fast* và *Slow*. Đây là thành phần học máy của hệ thống, nhận đầu vào từ các đặc trưng như khoảng cách, thời điểm giao hàng, loại tòa nhà, thời tiết, mức ưu tiên và đặc biệt là mức giao thông do mô-đun Bayes cung cấp.

Theo hướng tiếp cận của đề tài, dữ liệu huấn luyện được trích từ tập dữ liệu đơn hàng thực tế sau bước lọc và chuẩn hóa; các biến phân loại được mã hóa số, sau đó dữ liệu được chia theo tỷ lệ 80/20 cho tập huấn luyện và tập kiểm tra. Bộ phân lớp được chọn là `DecisionTreeClassifier` với độ sâu phù hợp để cân bằng giữa khả năng diễn giải và nguy cơ học quá khớp.

Cơ chế hoạt động của mô-đun là tìm thuộc tính và ngưỡng tách tốt nhất tại mỗi nút để phân biệt hai lớp ETA. Kết quả của mô-đun được đánh giá bằng Accuracy, Precision, Recall, F1-score và ma trận nhầm lẫn, đồng thời được dùng làm tín hiệu hỗ trợ cho bước điều phối sau cùng.

4.6 Tích hợp toàn hệ thống

Hệ thống được tích hợp theo kiến trúc pipeline, trong đó mỗi mô-đun đảm nhiệm một vai trò riêng nhưng liên kết chặt chẽ với các mô-đun còn lại.



Hình 4.2: Sơ đồ kiến trúc tổng thể của hệ thống AI phân công giao hàng.

Dữ liệu đầu vào ban đầu gồm thông tin đơn hàng, shipper, bản đồ đường đi và các yếu tố bối cảnh. Từ đó, mô-đun A* tính toán lộ trình và thời gian di chuyển dự kiến; mô-đun Bayes suy luận mức độ giao thông; mô-đun Decision Tree dự đoán nhãn ETA; hệ luật bổ sung kết luận nghiệp vụ; và cuối cùng mô-đun CSP tìm phương án phân công phù hợp nhất. Cách tích hợp này cho thấy hệ thống hoạt động như một pipeline AI hoàn chỉnh thay vì một tập hợp rời rạc của các thuật toán.

5 Dữ liệu và kịch bản thực nghiệm

Phần thực nghiệm của đề tài được xây dựng trên hai nhóm dữ liệu thực tế với vai trò khác nhau trong pipeline. Nhóm thứ nhất là dữ liệu giao thông đô thị dùng để xây dựng đồ thị đường đi cho mô-đun A*. Nhóm thứ hai là dữ liệu đơn hàng giao nhận dùng để đánh giá hoạt động điều phối trên quy mô lớn. Cách tổ chức này cho phép hệ thống vừa khai thác bản đồ giao thông ở mức hạ tầng, vừa xử lý dữ liệu vận hành ở mức đơn hàng thực tế.

5.1 Bộ dữ liệu sử dụng

Đối với mô-đun tìm đường, nhóm sử dụng bộ dữ liệu *Traffic Flow data in Ho Chi Minh City, Viet Nam* từ Kaggle¹ để xây dựng đồ thị giao thông phục vụ thuật toán A*. Từ nguồn dữ liệu này, các giao lộ và đoạn đường được chuyển thành cấu trúc đỉnh-cạnh có trọng số, trong đó mỗi cạnh mang thông tin khoảng cách và tốc độ lưu thông. Nhờ đó, hệ thống có thể tính

¹Nguồn dữ liệu: [Kaggle – Traffic Flow data in Ho Chi Minh City, Viet Nam](#).



toán lộ trình di chuyển giữa các điểm lấy hàng và giao hàng thay vì chỉ ước lượng bằng khoảng cách hình học.

Đối với dữ liệu đơn hàng, nhóm tham khảo bộ *Xe dù – Ho Chi Minh City delivery service Dataset* trên Kaggle² và đồng thời sử dụng tập dữ liệu vận hành chính từ file `data/uds-orders-aug2024.csv`. Đây là dữ liệu đơn hàng thực tế hoặc được trích xuất từ nền tảng thực, chứa các thông tin như mã đơn, thời điểm phát sinh, tọa độ lấy hàng, tọa độ giao hàng và các thuộc tính phục vụ điều phối. File này có tổng cộng 2403 bản ghi; sau bước lọc và chuẩn hóa, hệ thống nạp được khoảng 1648 đơn hàng khả dụng để đưa vào pipeline xử lý theo lộ trình thực nghiệm.

Từ các nguồn trên, hệ thống xây dựng tập biến đầu vào cho toàn bộ pipeline. Cụ thể:


- thông tin đơn hàng: *order_type*, *order_weight*;
- thông tin khách hàng: *is_vip*, *customer_location*, *building_type*;
- thông tin giao hàng: *distance_km*, *distance_category*, *delivery_time_requested*;
- yếu tố môi trường: *time_hour*, *day_of_week*, *is_rush_hour*, *is_weekend*, *weather*;
- biến suy luận: *traffic_level* do mô-đun Bayes cung cấp.

Các biến đầu ra chính của hệ thống gồm *eta_label*, *priority_level*, *estimated_surcharge* và *delivery_time_limit*. Cách tổ chức biến như vậy giúp báo cáo thể hiện rõ tính tích hợp giữa tìm đường, suy luận xác suất, hệ luật và học máy.

5.2 EDA dữ liệu

Ở mức khám phá dữ liệu, tập đơn hàng vận hành có quy mô đủ lớn để mô phỏng một chiến dịch điều phối thực tế, với 2403 bản ghi ban đầu và khoảng 1648 đơn hàng khả dụng sau bước lọc.

²Nguồn dữ liệu: [Kaggle – Xe dù delivery service dataset](#).



Hình 5.1: Tổng quan EDA, bao gồm phân bố khoảng cách giao hàng, khối lượng đơn hàng theo giờ trong ngày, ETA trung bình theo khoảng cách và tỷ lệ đơn hàng giao nhanh/giao chậm.

Sau khi chia lô, dữ liệu tạo thành 83 batch, trong đó phần lớn batch có 20 đơn hàng và batch cuối có 8 đơn. Cấu trúc này phù hợp với cách hệ thống xử lý hàng loạt trong thực tế và cho phép quan sát rõ sự khác biệt giữa các lô thành công và thất bại ở bước CSP.

Xét theo đặc trưng bài toán, dữ liệu có sự pha trộn giữa biến liên tục như khoảng cách, trọng lượng, thời gian và biến phân loại như loại hàng hóa, loại tòa nhà, thời tiết, trạng thái VIP hay mức độ giao thông. Điều này phù hợp với lựa chọn Decision Tree vì mô hình có thể xử lý tốt cả hai nhóm biến sau khi mã hóa. Ngoài ra, số lượng đơn được gắn nhãn *Slow* chiếm tỷ trọng đáng kể, phản ánh đúng bản chất vận hành giao hàng đô thị là nhiều đơn chịu ảnh hưởng bởi giao thông, thời tiết và ràng buộc thời gian. Đây là cơ sở hợp lý để xây dựng pipeline vừa có thành phần học máy, vừa có thành phần suy luận và tối ưu hóa.

5.3 Tiền xử lý dữ liệu

Quá trình tiền xử lý được thực hiện theo hai hướng. Với dữ liệu bản đồ, hệ thống chuẩn hóa thông tin vị trí để xây dựng đồ thị giao thông gồm các nút và cung có hướng, từ đó phục vụ mô-đun A*. Với dữ liệu đơn hàng, hệ thống loại bỏ các bản ghi không phù hợp, chuẩn hóa định dạng thời gian và tọa độ, sau đó tính thêm các thuộc tính dẫn xuất cần thiết cho pipeline như khoảng cách giao hàng, loại khoảng cách, giờ cao điểm hay cuối tuần. Đây là bước quan trọng để bảo đảm các mô-đun phía sau nhận được đầu vào nhất quán và có thể kết nối trực tiếp với nhau.

Riêng với mô-đun học máy, nhãn ETA không được lấy trực tiếp từ lịch sử vận hành của tài xế mà được suy ra trên chính tập dữ liệu đơn hàng thực tế sau khi chuẩn hóa, dựa trên các thuộc tính như khoảng cách, thời tiết, mức độ giao thông, loại tòa nhà và độ ưu tiên đơn hàng. Từ giá trị ETA ước tính này, hệ thống gán nhãn *Fast* nếu thời gian dưới 90 phút và *Slow* nếu

thời gian từ 90 phút trở lên. Sau đó, các biến phân loại được mã hóa về dạng số để phù hợp với `DecisionTreeClassifier`, và dữ liệu được chia theo tỷ lệ 80/20 cho tập huấn luyện và tập kiểm tra.

Đối với pipeline vận hành, dữ liệu được chia theo cơ chế batch processing để mô phỏng hoạt động thực tế. Mỗi lô xử lý tối đa 20 đơn hàng và được gán cho 5 shipper khả dụng. Các tham số ràng buộc chính của mô-đun CSP được thiết lập là $W_{max} = 50.0$ kg cho tải trọng tối đa của mỗi shipper và $T_{max} = 480$ phút cho thời gian làm việc tối đa của một ca. Nếu tổng khối lượng hoặc tổng thời gian giao hàng của một shipper vượt các ngưỡng này, hệ thống sẽ từ chối phương án phân công tương ứng. Cách thiết lập này giúp phần thực nghiệm phản ánh đúng giới hạn vật lý của bài toán giao hàng.

5.4 Các kịch bản kiểm thử

Kịch bản thực nghiệm trung tâm của đề tài là chạy xử lý hàng loạt trên toàn bộ tập 1648 đơn hàng khả dụng nhằm mô phỏng một chiến dịch điều phối hoàn chỉnh. Tập dữ liệu được chia thành 83 batch, trong đó đa số batch gồm 20 đơn hàng và batch cuối cùng gồm 8 đơn. Với mỗi batch, hệ thống lần lượt thực hiện các bước: tìm đường bằng A^* , suy luận mức giao thông bằng mạng Bayes, dự đoán nhãn ETA bằng Decision Tree, áp dụng hệ luật để bổ sung thông tin nghiệp vụ, rồi giải bài toán CSP để phân công đơn hàng cho 5 shipper.

Bên cạnh kịch bản tổng thể, nhóm còn kiểm tra các tình huống con tương ứng với từng mô-đun. Với mô-đun Bayes, hệ thống kiểm thử sự thay đổi của mức độ kẹt xe theo loại đường và khung giờ để đánh giá tác động của yếu tố bất định lên thời gian vận hành. Với mô-đun học máy và hệ luật, hệ thống kiểm tra các trường hợp như giờ cao điểm, thời tiết xấu, đơn hỏa tốc hoặc hàng nặng để quan sát sự thay đổi của nhãn ETA, mức ưu tiên và phụ phí. Những kiểm thử này giúp chứng minh rằng từng mô-đun đều có đóng góp riêng trong quyết định cuối cùng của pipeline.

Kịch bản quan trọng nhất của mô-đun CSP là phân biệt hai trường hợp thành công và thất bại. Một batch được xem là thành công khi thuật toán tìm được cấu hình phân công thỏa mãn đồng thời hai ràng buộc tải trọng và thời gian làm việc của toàn bộ shipper. Ngược lại, batch bị xem là thất bại nếu khối lượng hoặc thời gian giao hàng vượt quá khả năng chuyên chở của 5 shipper trong lô. Trên toàn bộ dữ liệu, hệ thống ghi nhận 42 batch thành công và 41 batch thất bại, tương ứng với 828 đơn hàng được phân công thành công. Tổng chi phí thời gian vận hành của các batch thành công đạt 86384.2 phút. Các số liệu này tạo cơ sở để bước tiếp theo phân tích sâu hơn hiệu quả của từng mô-đun và đánh giá chất lượng tích hợp của toàn hệ thống.


6 Kết quả thực nghiệm và đánh giá

Phần này tổng hợp các kết quả chính thu được từ quá trình chạy thực nghiệm trên dữ liệu đã mô tả ở mục trước. Trọng tâm đánh giá tập trung vào ba thành phần cốt lõi của hệ thống là mô-đun học máy dự đoán ETA, mô-đun Bayes suy luận giao thông và mô-đun CSP phân công shipper. Từ đó, báo cáo rút ra nhận xét tổng thể về hiệu quả của kiến trúc tích hợp mà nhóm đã xây dựng.

6.1 Kết quả mô-đun học máy

Mô-đun Decision Tree được huấn luyện trên 1404 mẫu dữ liệu, trong đó dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập kiểm tra. Kết quả đánh giá cho thấy độ chính xác tổng thể của mô hình đạt 66.19%, Precision đối với nhãn *Slow* đạt 67.14%, Recall đạt 84.43% và F1-score đạt 74.80%. Các con số này cho thấy mô hình chưa đạt độ chính xác tuyệt đối, nhưng lại có khả năng phát hiện khá tốt các đơn hàng có nguy cơ giao chậm, vốn là nhóm cần được quan tâm nhất trong bối cảnh vận hành thực tế.

KẾT QUẢ HUẤN LUYỆN MÔ HÌNH DECISION TREE (Độ chính xác: 66.2%)




Hình 6.1: Kết quả đánh giá mô-đun Decision Tree, gồm các chỉ số phân lớp và ma trận nhầm lẫn.

Ma trận nhầm lẫn của mô hình gồm 45 trường hợp dự đoán *Fast* đúng, 69 trường hợp dự đoán *Slow* sai, 26 trường hợp bỏ sót đơn *Slow* và 141 trường hợp dự đoán *Slow* đúng. Từ kết quả này có thể thấy mô hình có xu hướng nghiêng về phía an toàn, tức chấp nhận gần cờ chậm cho một số đơn thực ra giao nhanh, thay vì bỏ sót quá nhiều đơn hàng thật sự có rủi ro giao trễ. Trong bài toán điều phối giao hàng, đây là một sự đánh đổi hợp lý vì việc dự báo dư thời gian thường ít rủi ro hơn so với đánh giá quá lạc quan rồi dẫn đến trễ cam kết với khách hàng.

Xét về ý nghĩa vận hành, Recall cao là điểm mạnh đáng chú ý của mô-đun học máy. Khi hệ thống nhận diện đúng phần lớn các đơn hàng có khả năng *Slow*, các mô-đun phía sau có thể tận dụng thông tin này để gắn thêm phụ phí, điều chỉnh ưu tiên hoặc thay đổi phương án phân công. Do đó, dù Accuracy mới ở mức trung bình, mô hình Decision Tree vẫn thể hiện được giá trị thực tiễn rõ rệt trong toàn bộ pipeline AI của đề tài.

6.2 Kết quả suy luận Bayes

Mô-đun Bayes được sử dụng để suy luận mức độ giao thông từ các bằng chứng về khung giờ và loại đường. Ở tình huống thứ nhất, khi đầu vào là $Time = Peak$ và $Road = Main$, mạng Bayes suy ra xác suất mức giao thông *Low* là 66.06%, trong khi xác suất *High* là 18.78%. Với trường hợp này, nhãn điều hành được chọn là *Low*, tương ứng với hệ số phạt thời gian bằng $\times 1.0$. Kết quả cho thấy mô hình Bayes không chỉ đưa ra nhãn rời rạc mà còn cung cấp phân bố xác suất để hệ thống cân nhắc rủi ro mềm hơn.




Hình 6.2: Kết quả suy luận mức độ giao thông của mô-đun Bayes theo các bằng chứng đầu vào.

Ở tình huống thứ hai, khi $Time = Normal$ và $Road = Alley$, xác suất mức *Low* giảm còn 44.19%, trong khi *Medium* đạt 27.82% và *High* đạt xấp xỉ 28.0%. Phân bố này cho thấy rủi ro giao thông trong hẻm ở giờ thường không hẳn thấp, mà có xu hướng phân tán hơn so với đường chính vào giờ cao điểm. Điều đó phản ánh đúng vai trò của mô-đun Bayes: không tuyệt đối hóa một giả định duy nhất, mà mô hình hóa sự bất định theo xác suất.

Về mặt tác động lên pipeline, khi mạng Bayes xuất ra nhãn *Medium*, thời gian di chuyển được nhân với hệ số $\times 1.3$; nếu xuất ra *High*, hệ số phạt tăng lên $\times 1.6$. Chẳng hạn, một chuyến đi 30 phút sẽ tăng thành 39 phút trong trường hợp *Medium*, còn một chuyến 60 phút sẽ kéo dài thành 96 phút trong trường hợp *High*. Nhờ cơ chế này, kết quả suy luận Bayes được chuyển hóa trực tiếp thành tín hiệu định lượng để cập nhật ETA và thời gian công việc trong CSP.

6.3 Kết quả phân công bằng CSP

Trên toàn bộ 1648 đơn hàng khả dụng, hệ thống chia dữ liệu thành 83 batch để giải bài toán phân công cho 5 shipper trong mỗi lô. Kết quả cho thấy có 42 batch được giải thành công và 41 batch thất bại. Tổng số đơn hàng được phân công thành công là 828 đơn, với tổng chi phí thời gian vận hành của các batch thành công đạt 86384.2 phút. Các số liệu này cho thấy hệ thống đã giải được một phần đáng kể khối lượng công việc thực tế trong điều kiện ràng buộc chặt chẽ.



Hình 6.3: Kết quả phân công đơn hàng cho shipper bằng mô hình CSP trên toàn bộ dữ liệu.

Nguyên nhân chính của 41 batch thất bại không nằm ở lỗi thuật toán, mà xuất phát từ việc tổng khối lượng hoặc tổng thời gian của lô hàng vượt quá giới hạn vật lý cho phép của 5 shipper. Cụ thể, với 5 shipper, ngưỡng tải trọng tổng là 250 kg và ngưỡng thời gian tổng là 2400 phút cho mỗi batch. Trong những lô tập trung nhiều đơn nặng hoặc quãng đường quá xa, thuật toán backtracking nhánh cận không tìm được cấu hình nào vừa thỏa mãn ràng buộc tải trọng, vừa thỏa mãn ràng buộc thời gian. Việc hệ thống từ chối các batch như vậy cho thấy mô-đun CSP đã thực hiện đúng vai trò kiểm soát tính khả thi của phương án điều phối.

Từ góc nhìn ứng dụng, kết quả của mô-đun CSP có ý nghĩa thực tế rõ ràng. Một hệ thống điều phối tốt không nên cố gắng ép mọi batch đều thành công bằng cách vượt ràng buộc, mà phải có khả năng phát hiện sớm các lô quá tải để báo hiệu nhu cầu điều thêm shipper hoặc chia lại lô hàng. Vì vậy, tỷ lệ batch thất bại trong thí nghiệm này nên được hiểu như bằng chứng cho thấy hệ thống đã bảo vệ đúng các giới hạn an toàn vật lý, thay vì xem đó là một lỗi kỹ thuật đơn thuần.

6.4 Đánh giá toàn hệ thống

Nhìn tổng thể, hệ thống AI điều phối giao hàng của nhóm đã thể hiện được tính tích hợp rõ ràng giữa tìm kiếm, suy luận xác suất, hệ luật, học máy và tối ưu hóa ràng buộc. Mỗi mô-đun đảm nhiệm một vai trò khác nhau: A* giải quyết bài toán đường đi, Bayes bổ sung yếu tố bất định, Decision Tree cung cấp tín hiệu dự báo rủi ro, còn CSP là bước kiểm tra tính khả thi cuối cùng. So với cách tiếp cận đơn mô-đun, pipeline tích hợp cho phép hệ thống đưa ra quyết định giàu ngữ cảnh hơn và giải thích rõ hơn nguyên nhân khi một lô hàng thất bại hoặc một đơn hàng bị dự báo trễ.

Xét theo hướng ứng dụng, kết quả thực nghiệm mang ý nghĩa tích cực. Tỷ lệ batch thất bại cao không phản ánh lỗi phần mềm mà cho thấy hệ thống tôn trọng đúng các giới hạn tải



trọng và thời gian làm việc của shipper. Đồng thời, Recall cao đối với nhãn *Slow* cho thấy hệ thống nhận diện tốt các đơn hàng rủi ro, từ đó hỗ trợ cảnh báo sớm và điều chỉnh phương án vận hành.

Tuy vậy, hệ thống vẫn còn một số hạn chế: nhãn ETA hiện được suy ra từ quy tắc ước tính trên dữ liệu thực thay vì lấy trực tiếp từ lịch sử giao hàng đã gắn nhãn, mô hình Bayes mới xét số lượng biến còn ít, còn CSP vẫn hoạt động theo từng batch cục bộ. Dù vậy, xét theo mục tiêu của học phần, hệ thống hiện tại đã đáp ứng tốt yêu cầu xây dựng một pipeline AI hoàn chỉnh cho bài toán điều phối giao hàng.

7 Kết luận và hướng phát triển

7.1 Kết luận

Đề tài đã xây dựng được một hệ thống AI tích hợp cho bài toán điều phối shipper trong bối cảnh giao hàng đô thị. Pipeline của hệ thống kết hợp A* cho tìm đường, mạng Bayes cho suy luận bất định, Decision Tree cho dự đoán ETA, hệ luật IF-THEN cho tri thức nghiệp vụ và CSP cho bước phân công cuối cùng. Cấu trúc này đáp ứng đầy đủ tinh thần học phần: kết hợp tìm kiếm, biểu diễn tri thức, xác suất và học máy trong một hệ thống thống nhất.

Về mặt thực nghiệm, hệ thống xử lý được dữ liệu vận hành ở quy mô tương đối lớn, nhận diện tốt các đơn có nguy cơ giao chậm nhờ Recall cao của nhãn *Slow*, đồng thời phát hiện các batch vượt giới hạn tải trọng hoặc thời gian làm việc thông qua CSP. Nhìn chung, đề tài vừa có giá trị minh họa học thuật rõ ràng, vừa cho thấy tiềm năng ứng dụng thực tế cho bài toán giao hàng.

7.2 Hướng phát triển

Trong tương lai, hệ thống có thể được cải thiện theo ba hướng chính: bổ sung dữ liệu lịch sử giao hàng đã gắn nhãn ETA thực để tăng độ tin cậy của mô hình học máy; mở rộng mạng Bayes và mô-đun tối ưu hóa bằng cách bổ sung thêm biến bối cảnh như thời tiết, ngày trong tuần hoặc sự kiện đặc biệt; và hoàn thiện hệ thống ở mức ứng dụng với dashboard trực quan, cập nhật thời gian thực và tích hợp API bản đồ hoặc giao thông. Các hướng này sẽ giúp mô hình sát thực tế hơn và nâng cao khả năng triển khai thực tế.